Analisis & Implementasi Klasifikasi Keterlambatan Pengiriman Logistik

dengan Perceptron dan Adaline

- 71241073 | Stefanus Westin Giovanno Mursito
- 71241075 | Giovanni Albert Harjanto
- 71241079 | Natalie Neysa Jessica Soesanto
- 71241123 | Fransiska
- 71241150 | Kevin Surya Saputra

Latar Belakang

- Keterlambatan pengiriman logistik e-commerce menurunkan retensi dan menimbulkan penalti biaya.
- Formulasi yang digunakan: Klasifikasi Biner metode *Supervised Learning*.
  - Label +1 (Positif): Terlambat (late_delivery = Yes)
  - Label -1 (Negatif): Tepat waktu (late_delivery = No)
- Dataset: *E-commerce Delivery & Shipping Data 2026* (Kaggle, lisensi CC0 1.0).
- *Data Integrity & Data Leakage Prevention*:
  - Total 50.000 pesanan, 0 missing values, 0 duplikat.
  - Membuang 8 kolom bocor yang baru tercatat pasca-pengiriman (contoh: *actual_delivery_days, delivery_delay_days, delivery_attempts, rating*)
  - 14 fitur awal yang terpilih akan dienkode menjadi 43 fitur numerik (ordinal + one-hot drop first).
- Kelas yang dihasilkan: Terlambat 56,32% vs Tepat Waktu 43,68% (Baseline mayoritas: 56,32%).

Model

- Neuron Identik: $z = w^T x + b$. Prediksi $\hat{y} = +1$ jika $z \geq 0$, else -1.
- Perbedaan Inti Mekanisme Error:
  a. Perceptron (Rosenblatt, 1958):
    - Error Diskret: $\Delta = \eta(y - \hat{y}) \in 0, \pm 2\eta$.
    - Pembaruan *online* per sampel hanya saat salah tebak. Buta terhadap margin/keyakinan.
  b. ADALINE (Widrow & Hoff, 1960):
    - Error Kontinu Linear: $e = y - z$.
    - Fungsi Biaya Kuadratik: $J = \frac{1}{2n}\sum e_i^2$
    - Pembaruan *Batch Gradient Descent*: $w \leftarrow w + \eta\frac{X^T e}{n}$.
    - Ambang kelas hanya diaktifkan saat inferensi/prediksi.

- Validasi Perhitungan Manual: Menggunakan 2 sampel Perceptron & 2 iterasi batch ADELINE yang dihitung manual dan lols uji ‘assert’ identik dengan kode NumPy.

Pelatihan & Pengendalian Eksperimen

Prinsip Validitas Ilmiah:

- Split Stratified 80:20 $(n_{\text{train}} = 40.000, n_{\text{test}} = 10.000)$, `random_state = 42`
- Imputer & Scaler hanya di pakai pada data latih.
- Inisiasi awal / nol (w0 = 0, b0 = 0), 50 epoch, urutan data statis.

8 Konfigurasi Terkontrol:

1. Perceptron terstandardisasi: $\eta \in 0.001, 0.01, 0.1$
2. ADALINE terstandardisasi: $\eta \in 0.001, 0.01, 0.1$
3. Kontrol tanpa standardisasi: $\eta = 0.01$ & ADALINE $\eta = 0.01$

Hasil Eksperimen

ADALINE		Perceptron	
$\eta =$	Hasil	$\eta =$	Hasil
0.1	Terbaik: Akurasi 79.43%, Precision(+1) 82.40%, Recall(+1) 80.72%, F1(+1) 81.55%, Loss J = 0.2898	0.1 , 0.01 , 0.0001	Akurasi mirip 74.60%, F1(+1) 76.93%, 10674 pembaruan di epoch 50
0.01	Akurasi 76.76, J = 0.3578		
0.001	Akurasi 74.03%, J = 0.4724 (belum mendekati 50 epoch)		
Tanpa Standardisasi	Divergen Numerik (J → ♾️) di epoch 31.	Tanpa Standardisasi	Akurasi jatuh ke 44.37% (recall0.0217 => gagal total)

Data Terpisah Tidak Linear

- Perceptron tidak pernah konvergen (≈10.670 pembaruan konstan per epoch).
- Batas optimum fisik Ordinary Least Squares adalah JLS=0.2881 (akurasi 79,47%).
- Histogram d=z/|w| tumpang tindih padat di sekitar 0 (20,6% salah posisi).

Mengapa 3 η Perceptron Identik?

Pada inisialisasi nol & urutan statis, w=ηv. Karena η>0, sign(wTx)=sign(vTx). η hanya menskalakan norma bobot (10×).

Mengapa Tanpa Standardisasi ADALINE Meledak?

- Hessian $\lambda_{\max} = 9,47 \times 10^{6} \implies$ batas stabil $\eta < 2,11 \times 10^{-7}$.
- Pemakaian $\eta = 0.01$ melanggar batas stabilitas $47.000\times \implies$ faktor pembesaran $(1 - \eta\lambda_{\max})^{2} \approx 8,96 \times 10^{9}$ per epoch $\implies J = 1.4 \times 10^{297}$ di epoch 30!

Fitur Penentu Keterlambatan

- Positif (Pemicu Terlambat): Cuaca Salju (+0.32), Badai (+0.30), Hujan (+0.21), Jarak (+0.19).
- Negatif (Mencegah Terlambat): Prioritas Pesanan (−0.26), Pengiriman Same Day/Express (−0.08).

Keterbatasan & Rekomendasi

- Model linear terbatas pada hyperplane tunggal — tidak mampu memodelkan interaksi silang fitur non-linear (misalnya cuaca buruk & jarak jauh).
- Akurasi 79,4% adalah batas matematis model linear pada data ini.

Rekomendasi Lanjutan:

- Pocket Algorithm (Gallant, 1990) untuk menstabilkan osilasi Perceptron (+1,4% akurasi).
- Multi-Layer Perceptron (MLP) dengan lapisan tersembunyi non-linear (ReLU/Sigmoid) dan Backpropagation.
- Regresi Logistik untuk kalibrasi probabilitas risiko keterlambatan.

Kesimpulan

- Implementasi mandiri NumPy Perceptron & ADALINE sukses membedakan keterlambatan logistik.
- ADALINE $\eta=0.1$ terbukti paling unggul dan stabil mendekati solusi kuadrat terkecil analitis.
- Standardisasi fitur terbukti krusial secara matematis untuk mencegah divergensi numerik.
- Seluruh kode, gambar, tabel, dan notebook tersedia lengkap & dapat diulang (reproducible) di GitHub.