LAPORAN TUGAS BESAR 1
JARINGAN SYARAF TIRUAN

ANALISIS DAN IMPLEMENTASI KLASIFIKASI KETERLAMBATAN PENGIRIMAN *E-COMMERCE* MENGGUNAKAN PERCEPTRON DAN ADALINE



Nama Kelompok: Kelompok Bebas

Nama Lengkap	NIM
Stefanus Westin Giovanno Mursito	71241073
Giovanni Albert Harjanto	71241075
Natalie Neysa Jessica Soesanto	71241079
Fransiska	71241123
Kevin Surya Saputra	71241150

Repositori: https://github.com/albertharjanto/TB1-JST-Kelompok_Bebas

PROGRAM STUDI INFORMATIKA
FAKULTAS TEKNOLOGI INFORMASI
UNIVERSITAS KRISTEN DUTA WACANA
YOGYAKARTA

Semester Gasal Tahun Akademik 2026/2027

1. MASALAH DAN TUJUAN

1.1 Latar Belakang dan Rumusan Masalah

Dalam ekosistem logistik perdagangan elektronik (*e-commerce*), ketepatan waktu pengiriman merupakan indikator kinerja utama (*Key Performance Indicator*) yang menentukan kepuasan dan loyalitas pelanggan serta efisiensi operasional perusahaan pengiriman. Keterlambatan dapat menimbulkan komplain, denda ganti rugi, hingga penurunan retensi pelanggan. Dengan volume pengiriman yang mencapai puluhan ribu paket per hari, penyaringan manual terhadap pesanan yang berisiko terlambat menjadi tidak realistis.

Masalah ini dirumuskan sebagai **klasifikasi biner terawasi** (*supervised learning*): model memetakan atribut pesanan $x \in \mathrm{R}^d$ yang sudah diketahui saat pesanan diproses ke label diskret $y \in \{-1, +1\}$. Kelas positif ($y = +1$) adalah **Terlambat** (*late_delivery* = Yes) dan kelas negatif ($y = -1$) adalah **Tepat Waktu** (*late_delivery* = No).

1.2 Tujuan Eksperimen

1. Membangun model neuron tunggal berbobot dan berbias untuk kasus keterlambatan pengiriman *e-commerce*.
2. Mengimplementasikan algoritma Perceptron (Rosenblatt, 1958) dan ADALINE (*Adaptive Linear Neuron* atau Delta Rule; Widrow & Hoff, 1960) secara mandiri dengan NumPy tanpa kelas estimator siap pakai.
3. Menunjukkan secara manual adaptasi bobot kedua model dan memvalidasinya terhadap kode.
4. Menjalankan 8 konfigurasi eksperimen terkontrol (variasi laju belajar $\eta \in \{0{,}001;\ 0{,}01;\ 0{,}1\}$ dan pengaruh standardisasi fitur) untuk mengamati konvergensi, osilasi, dan divergensi numerik.
5. Menganalisis separabilitas linear data serta batas kemampuan neuron tunggal berdasarkan riwayat pelatihan dan karakteristik ruang fitur.

2. DATASET DAN KARAKTERISTIK DATA

2.1 Sumber Data dan Kesinambungan Tugas 1

Dataset merupakan kelanjutan dari Tugas 1, yaitu *E-commerce Delivery and Shipping Data 2026* dari repositori publik Kaggle dengan lisensi *Creative Commons CC0 1.0 Universal (Public Domain Dedication)*. Data bebas dari batasan hak cipta dan tidak memuat data pribadi pelanggan (*Personally Identifiable Information*).

2.2 Jumlah Observasi dan Fitur Masukan

Data mentah memuat 50.000 observasi dan 30 kolom. Untuk mencegah **kebocoran data (*data leakage*)**, delapan kolom yang baru diketahui saat atau setelah pengiriman dibuang: *actual_delivery_days*, *delivery_delay_days*, *delivery_status*, *tracking_status*, *return_requested*, *return_reason*, *customer_rating*, dan *delivery_attempts*. Kolom identitas, lokasi, dan tanggal juga tidak dipakai, sehingga *dataset.csv* berukuran 50.000 baris × 16 kolom (satu pengenal, 14 fitur operasional, satu target). Ringkasan fitur ada pada Tabel 1.

Tabel 1. Ringkasan fitur masukan

Kelompok	Fitur	Rentang / level
Numerik kontinu (6)	*product_weight_kg*, *order_value_usd*, *distance_km*, *promised_delivery_days*, *shipping_cost_usd*, *warehouse_processing_hours*	Berat 0,10–52,19 kg; nilai pesanan USD 10,00–3.530,73; jarak 40,0–9.553,6 km; janji pengiriman 0–15 hari; ongkos kirim USD 4,05–500,00; proses gudang 1,0–48,0 jam
Ordinal (2)	*package_size*, *order_priority*	Small < Medium < Large < Oversized; Low < Normal < High < Urgent
Nominal (6)	*customer_segment*, *product_category*, *shipping_method*, *carrier*, *payment_method*, *weather_condition*	4, 12, 5, 8, 6, dan 6 level secara berurutan (cuaca: Clear, Cloudy, Extreme Heat, Rain, Snow, Storm)

2.3 Kualitas Data dan Distribusi Kelas

Data lengkap (0 nilai hilang), tanpa baris duplikat maupun duplikasi *order_id*, dan tanpa konflik (fitur identik dengan target berlawanan). Distribusi kelas: Terlambat (+1) sebanyak 28.162 observasi (56,32%) dan Tepat Waktu (−1) sebanyak 21.838 observasi (43,68%). Karena kelas relatif seimbang namun sedikit condong ke kelas terlambat, kinerja dievaluasi dengan akurasi serta *precision*, *recall*, dan *F1-score* kelas positif, lalu dibandingkan dengan garis dasar mayoritas (*Zero-R*) dengan akurasi 0,5632. Eksplorasi awal (Lampiran E) menunjukkan cuaca bersalju atau badai meningkatkan peluang terlambat, tetapi pada setiap kategori kedua kelas tetap bercampur.

3. ARTIKEL ILMIAH DAN KODE PENDUKUNG

3.1 Penelusuran Artikel Ilmiah

Lima artikel ilmiah menjadi rujukan eksperimen ini (Tabel 2).

Tabel 2. Artikel ilmiah rujukan dan kontribusinya

Sumber	Kontribusi pada tugas
Rosenblatt (1958). *Psychological Review*, 65(6), 386–408	Dasar aturan pembaruan Perceptron dan teorema konvergensi: jika data terpisah linear, pembaruan berhenti dalam langkah terhingga.
Widrow & Hoff (1960). *IRE WESCON Convention Record*, Part 4, 96–104	Merumuskan ADALINE dan aturan *Least Mean Squares* (Delta Rule): galat dari keluaran linear dan pembaruan menurut gradien biaya kuadrat.
Pratama, Anrahvi, Tambal, & Singh (2025). *PREDATECS*, 3(1)	Rujukan domain ketepatan waktu pengiriman *e-commerce*; akurasi terbaiknya sekitar 66%, menandakan kasus ini sulit dan berderau.
LeCun, Bottou, Orr, & Müller (1998). *Efficient BackProp*	Alasan standardisasi fitur: kondisi matriks Hessian memengaruhi kestabilan penurunan gradien.
Gallant (1990). *IEEE Trans. Neural Networks*, 1(2), 179–191	*Pocket algorithm* sebagai pengembangan Perceptron untuk data yang tidak terpisah linear.

3.2 Kode Rujukan dan Modifikasi

Kode rujukan adalah Bab 2 repositori buku *Python Machine Learning* (Raschka & Mirjalili, 2019) dan dokumentasi pustaka *mlxtend* untuk kelas Adaline. Struktur kelas (*fit*, *net_input*, *predict*) dan pencatatan riwayat diadaptasi dengan perubahan berikut:

1. Pembaruan Perceptron memakai $\Delta = \eta(y - \hat{y})$ (besar $\pm 2\eta$ saat salah), ambang $\hat{y} = +1$ jika $z \geq 0$, label $-1/+1$, dan bobot awal nol (rujukan memakai bobot acak kecil).
2. ADALINE memakai *full-batch gradient descent* dengan biaya $J = (1/2n)\Sigma e^2$ yang dicatat setelah pembaruan tiap epoch, ditambah J awal dan MSE.
3. Deteksi divergensi numerik (*NaN*/*Inf*): pelatihan dihentikan, epoch kejadian dicatat, dan parameter terakhir yang berhingga dikembalikan.
4. Pencatatan jumlah pembaruan, akurasi latih, dan riwayat bobot per epoch, serta *Preprocessor* mandiri yang hanya dipelajari dari data latih; seluruh modul hanya bergantung pada NumPy.

4. MODEL NEURON DAN ATURAN PEMBELAJARAN

4.1 Persamaan Neuron Tunggal

Perceptron dan ADALINE memakai komputasi neuron linear yang identik:

$$z = \boldsymbol{w}^{\mathrm{T}}\boldsymbol{x} + b = \Sigma_{j=1}^{d} w_j x_j + b \tag{1}$$

dengan $\boldsymbol{w}$ vektor bobot, b bias, $\boldsymbol{x}$ vektor fitur, dan z masukan bersih (*net input*). Keputusan biner ditentukan fungsi ambang:

$$\hat{y} = +1 \text{ jika } z \geq 0; \quad \hat{y} = -1 \text{ jika } z < 0 \tag{2}$$

4.2 Perbedaan Aturan Pembelajaran dan Fungsi Objektif

Perbedaan kedua model terletak pada cara galat dihitung dan bobot diperbarui (Tabel 3). Perceptron bersifat buta terhadap margin: pembaruan bernilai $\pm 2\eta$ tanpa memedulikan apakah sampel dekat atau jauh dari batas keputusan. ADALINE memakai galat kontinu $e_i = y_i - z_i$ sehingga besar pembaruan sebanding dengan deviasi, dan meminimalkan fungsi biaya berikut dengan gradien $\nabla_w J = -\boldsymbol{X}^{\mathrm{T}}\boldsymbol{e}/n$ dan $\partial J/\partial b = -\mathrm{mean}(\boldsymbol{e})$:

$$J(\boldsymbol{w}, b) = (1/2n)\, \Sigma_{i=1}^{n} (y_i - z_i)^2 \tag{3}$$

Tabel 3. Perbandingan aturan pembelajaran Perceptron dan ADALINE

Aspek	Perceptron (Rosenblatt)	ADALINE (Delta Rule / LMS)
Mode pembelajaran	Per sampel (*online*)	*Full-batch gradient descent*
Galat	Diskret: $y - \hat{y} \in \{-2, 0, +2\}$	Kontinu: $e = y - z$
Pembaruan	$\Delta = \eta(y - \hat{y})$; $\boldsymbol{w} \leftarrow \boldsymbol{w} + \Delta\boldsymbol{x}$; $b \leftarrow b + \Delta$	$\boldsymbol{w} \leftarrow \boldsymbol{w} + \eta\boldsymbol{X}^{\mathrm{T}}\boldsymbol{e}/n$; $b \leftarrow b + \eta \cdot \mathrm{mean}(\boldsymbol{e})$
Tujuan implisit	Mengurangi salah klasifikasi	Meminimalkan J (MSE = $2J$)

4.3 Verifikasi Perhitungan Manual

Perhitungan manual dilakukan pada 4 sampel data latih terstandardisasi dengan tiga fitur (*distance_km*, *promised_delivery_days*, *warehouse_processing_hours*), $\eta = 0{,}1$, $\boldsymbol{w}_0 = \boldsymbol{0}$, dan b_0

= 0; rincian ada pada Lampiran A. Pada Perceptron, dua langkah pertama menghasilkan $\boldsymbol{w}$ = $[-0{,}0616;\ -0{,}4348;\ -0{,}0121]^{T}$ dan b = 0,0000. Pada ADALINE, biaya turun dari 0,5000 ke 0,4679 lalu 0,4394 setelah dua iterasi *batch*. Seluruh nilai identik dengan keluaran kelas *Perceptron* dan *AdalineGD* (diverifikasi dengan *assert*).

5. PENYIAPAN DATA DAN RANCANGAN EKSPERIMEN

5.1 Pembagian Data Bebas Kebocoran

Data dibagi 80% data latih (40.000 sampel) dan 20% data uji (10.000 sampel) dengan *stratified train-test split* (*random_state* = 42), sehingga proporsi kelas positif tetap 56,32% pada kedua subset dan irisan indeks latih–uji kosong. Seluruh konfigurasi ditetapkan sebelum melihat data uji, dan pemilihan model terbaik memakai data validasi (20% dari data latih).

5.2 Skema Preprocessing

Kelas *Preprocessor* mandiri dipelajari **hanya dari data latih**, lalu diterapkan secara deterministik ke data uji tanpa perhitungan ulang. Langkahnya: (1) imputasi median/modus (disiapkan walau tidak ada nilai hilang); (2) *ordinal encoding* {0, 1, 2, 3} untuk *package_size* dan *order_priority*; (3) *one-hot encoding drop-first* untuk 6 fitur nominal sehingga dimensi akhir menjadi **43 fitur**; (4) standardisasi *z-score* dengan rata-rata μ_j dan simpangan baku σ_j dari data latih pada versi terstandardisasi, sedangkan versi tanpa standardisasi dibiarkan pada skala asli untuk dua eksperimen pembanding. Rata-rata fitur data uji tidak persis nol ($|\mu_{\text{uji}}| \leq 0{,}025$), bukti bahwa *scaler* tidak melihat data uji.

5.3 Rancangan Eksperimen 8 Konfigurasi

Seluruh konfigurasi dilatih 50 epoch dengan $\boldsymbol{w}_0 = \mathbf{0}$, $b_0 = 0$, dan urutan sampel tetap: (1–3) Perceptron terstandardisasi dengan $\eta \in \{0{,}001;\ 0{,}01;\ 0{,}1\}$; (4–6) ADALINE terstandardisasi dengan η yang sama; (7) Perceptron tanpa standardisasi (η = 0,01); dan (8) ADALINE tanpa standardisasi (η = 0,01).

6. HASIL EKSPERIMEN

6.1 Ringkasan Kinerja Seluruh Konfigurasi

Kinerja pada data latih (n = 40.000) dan data uji (n = 10.000) disajikan pada Tabel 4.

Konfigurasi terbaik adalah **ADALINE terstandardisasi dengan η = 0,1**, yang juga terpilih lewat data validasi (akurasi validasi 0,7996). Pada data uji model ini mencapai akurasi 0,7943, *precision* 0,8240, *recall* 0,8072, dan *F1-score* 0,8155 (Tabel 4), jauh di atas garis dasar mayoritas.

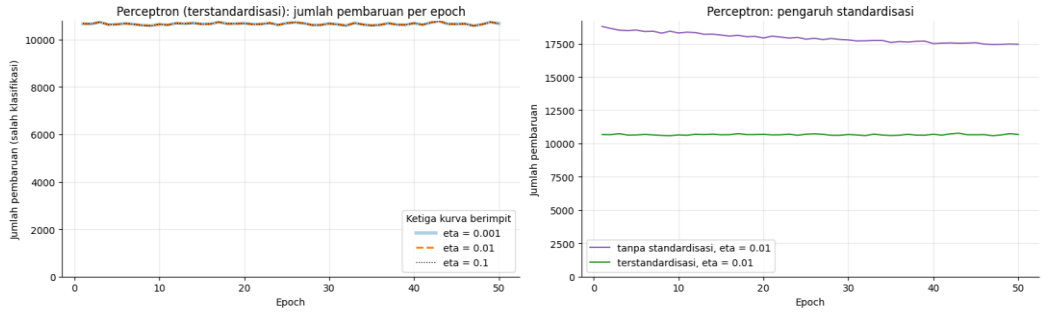
Tabel 4. Kinerja delapan konfigurasi pada epoch ke-50

Model	η	Std.	Akurasi latih	Akurasi uji	Precision (+1)	Recall (+1)	F1 (+1)	Pembaruan / J akhir
Perceptron	0,001	Ya	0,7443	0,7460	0,7874	0,7521	0,7693	10.674 pembaruan
Perceptron	0,01	Ya	0,7443	0,7460	0,7874	0,7521	0,7693	10.674 pembaruan
Perceptron	0,1	Ya	0,7443	0,7460	0,7874	0,7521	0,7693	10.674 pembaruan
ADALINE	0,001	Ya	0,7428	0,7403	0,7958	0,7250	0,7587	$J = 0{,}4724$
ADALINE	0,01	Ya	0,7683	0,7676	0,8096	0,7679	0,7882	$J = 0{,}3578$
ADALINE	**0,1**	**Ya**	**0,7959**	**0,7943**	**0,8240**	**0,8072**	**0,8155**	$\boldsymbol{J = 0{,}2898}$
Perceptron	0,01	Tidak	0,4430	0,4437	0,6971	0,0217	0,0420	17.447 pembaruan
ADALINE	0,01	Tidak	0,4368	0,4368	0,0000	0,0000	0,0000	Divergen ($J = \infty$, epoch 31)

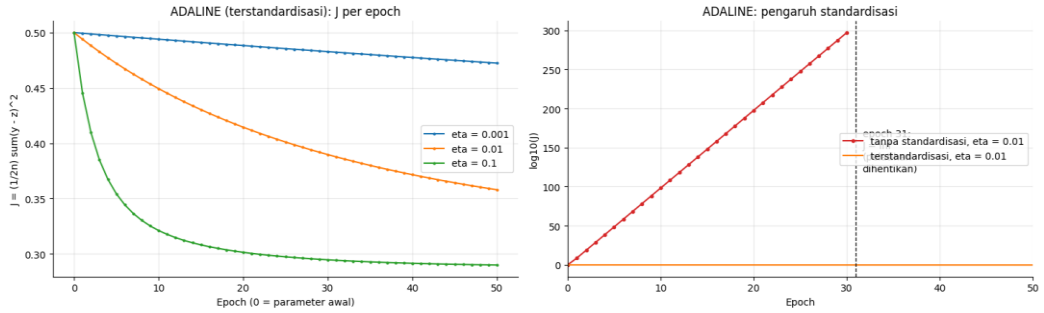
Garis dasar mayoritas (*Zero-R*): akurasi 0,5632; *recall* (+1) 1,0000; *precision* (+1) 0,5632. ADALINE tanpa standardisasi divergen pada epoch 31; pelatihan dihentikan otomatis dan parameter epoch 30 dipakai.

6.2 Kurva Pelatihan

Jumlah pembaruan Perceptron terstandardisasi tetap di sekitar 10.670 per epoch dan ketiga η berimpit (Gambar 1), sedangkan biaya J ADALINE turun mulus dan paling cepat pada $\eta = 0{,}1$ (Gambar 2). Kondisi pada epoch ke-10, ke-30, dan ke-50 dirinci pada Lampiran B.



Gambar 1. Pembaruan Perceptron per epoch dan pengaruh standardisasi



Gambar 2. Biaya J ADALINE per epoch dan pengaruh standardisasi

6.3 Matriks Kebingungan, Bobot, dan Bias

Pada data uji, ADALINE $\eta = 0{,}1$ menghasilkan TN = 3.397, FP = 971, FN = 1.086, dan TP = 4.546 (Lampiran C). ADALINE tanpa standardisasi memprediksi seluruh sampel sebagai −1 (TN = 4.368, FN = 5.632), sedangkan Perceptron tanpa standardisasi hanya memprediksi 175 sampel positif dari 10.000 sampel uji.

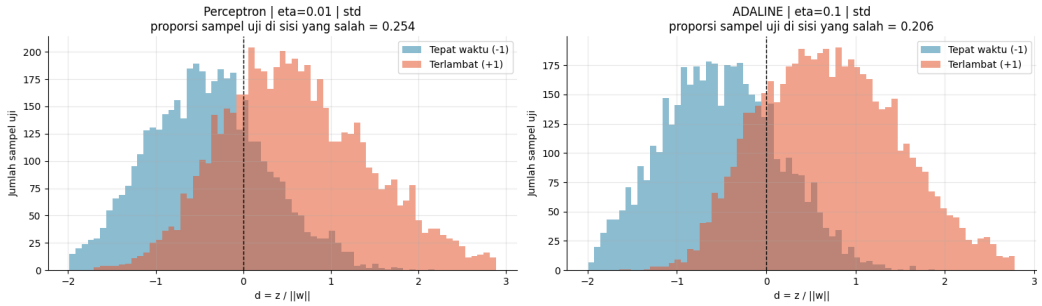
Bias akhir Perceptron (η = 0,01) adalah +0,2000 dengan $\|\boldsymbol{w}\|$ = 1,0926, sedangkan ADALINE (η = 0,1) memiliki b = +0,1258 dengan $\|\boldsymbol{w}\|$ = 0,6558; kosinus arah bobot keduanya 0,8591. Pada ADALINE, fitur paling berpengaruh adalah *weather_condition=Snow* (+0,3179), *Storm* (+0,2990), *order_priority* (−0,2584), *Rain* (+0,2062), dan *distance_km* (+0,1860); bobot positif mendorong ke kelas Terlambat. Daftar bobot terbesar ada pada Lampiran D.

7. PEMBAHASAN DAN KETERBATASAN

7.1 Indikasi Separabilitas Linear Data

Berdasarkan perilaku pelatihan dan pola data, **data ini menunjukkan indikasi kuat tidak terpisah secara linear**:

1. **Perceptron tidak konvergen.** Teorema konvergensi menjamin pembaruan berhenti jika data terpisah linear. Pada eksperimen ini jumlah pembaruan tetap 10.642 (epoch 10), 10.673 (epoch 30), dan 10.674 (epoch 50), atau sekitar 26,7% data latih masih memicu pembaruan di setiap epoch (Gambar 1).
2. **Akurasi latih Perceptron berosilasi** antara 0,7304 dan 0,7575 (simpangan baku 0,0066) tanpa tren naik (Lampiran E).
3. **Optimum *least squares* jauh dari nol.** Minimum global J untuk model linear adalah J_{LS} = 0,2881 (akurasi uji 0,7947). Residual sebesar ini menunjukkan tidak ada hyperplane tunggal yang memisahkan kedua kelas tanpa kesalahan.
4. **Distribusi jarak bertanda tumpang-tindih.** Histogram $d = z/\|\boldsymbol{w}\|$ (Gambar 3) memperlihatkan kedua kelas bertumpuk di sekitar d = 0, dan 20,6% sampel uji tetap berada di sisi yang salah pada ADALINE terbaik. PCA 2D dan model bantu dua fitur dengan akurasi uji ≈ 0,67 (Lampiran E) menunjukkan sebaran yang sama.



Gambar 3. Distribusi jarak bertanda sampel uji ke hyperplane

Dengan demikian kedua model hanya menemukan hyperplane kompromi, dan batas atas akurasi model linear pada data ini berada di sekitar 79–80%.

7.2 Perbedaan Mekanisme Pembelajaran Galat

Galat diskret Perceptron membuat bobot akhirnya ditentukan oleh beberapa ratus sampel salah terakhir. Akibatnya kosinus arah bobotnya terhadap ADALINE hanya 0,8591, dan fitur yang praktis tidak berguna menurut ADALINE justru mendapat bobot besar pada Perceptron (misalnya *product_category=Home & Kitchen*: ADALINE +0,0005, Perceptron −0,1352). Sebaliknya, galat kontinu dan pembaruan *full-batch* membuat ADALINE η = 0,1 mencapai J = 0,2898, hanya 0,6% di atas J_{LS}, dengan kosinus arah bobot terhadap solusi *least squares*

sebesar 0,9913 dan akurasi uji 0,7943 (*least squares*: 0,7947). Kedua model sepakat pada fitur dominan (cuaca buruk dan jarak mendorong ke terlambat; prioritas tinggi dan pengiriman *Same Day*/*Express* mendorong ke tepat waktu), konsisten dengan hasil eksplorasi data.

7.3 Pengaruh Laju Belajar, Epoch, dan Standardisasi

Laju belajar pada Perceptron tidak mengubah hasil. Dengan $\boldsymbol{w}_0 = \mathbf{0}$, $b_0 = 0$, dan urutan sampel tetap, setiap pembaruan bernilai $\pm 2\eta\boldsymbol{x}$ sehingga bobot setelah t langkah adalah

$$\boldsymbol{w}_t(\eta) = \eta \sum_{k \in M_t} (y_k - \hat{y}_k)\boldsymbol{x}_k = \eta \boldsymbol{v}_t \tag{4}$$

dengan M_t himpunan sampel yang salah diklasifikasi. Karena $\eta > 0$, tanda z tidak bergantung pada η sehingga urutan salah klasifikasi identik. Norma bobot membesar tepat 10× (0,1093; 1,0926; 10,9263) dan ketiga konfigurasi menghasilkan prediksi yang sama. Pada inisialisasi acak kecil $N(0; 0{,}01)$ invariansi ini gugur dan akurasi uji menjadi 0,7485; 0,7337; 0,7454 karena rasio $2\eta/\|\boldsymbol{w}_0\|$ berubah.

Laju belajar pada ADALINE sangat berpengaruh. Setelah 50 epoch, J = 0,4724; 0,3578; dan 0,2898 untuk η = 0,001; 0,01; dan 0,1. Pada data terstandardisasi nilai eigen terbesar matriks Hessian adalah $\lambda_{\text{maks}} = 3{,}081$ sehingga batas stabil $\eta < 2/\lambda_{\text{maks}} = 0{,}649$; ketiga η berada di bawahnya. η = 0,001 terlalu kecil sehingga belum mencapai optimum dalam 50 epoch.

Jumlah epoch. Kondisi Perceptron pada epoch 10, 30, dan 50 praktis sama, dan bobot terakhir belum tentu terbaik: bobot epoch 18 memiliki akurasi latih tertinggi (0,7575) dan akurasi uji 0,7600, lebih baik daripada epoch 50 (0,7460), yang menjadi motivasi *pocket algorithm*. Pada ADALINE $\eta = 0{,}1$, J turun monoton dari 0,3210 (epoch 10) ke 0,2898 (epoch 50).

Standardisasi menentukan stabilitas. Tanpa standardisasi, *distance_km* yang bernilai ribuan mendominasi sehingga $\lambda_{\text{maks}} = 9{,}467 \times 10^{6}$ dan batas stabil turun menjadi $\eta < 2{,}1 \times 10^{-7}$. ADALINE dengan $\eta = 0{,}01$ melanggar batas ini sekitar 47.000×; faktor pertumbuhan teoretis $(1 - \eta\lambda_{\text{maks}})^2 \approx 8{,}96 \times 10^{9}$ per epoch sama persis dengan yang teramati, sehingga J mencapai $1{,}43 \times 10^{297}$ pada epoch 30 lalu tak hingga pada epoch 31 dan seluruh prediksi uji bernilai −1. Perceptron tanpa standardisasi tidak meledak, tetapi nilai z didominasi *distance_km* (rata-rata $|w_j x_j| \approx 39.087$) sehingga fitur biner cuaca dan metode pengiriman tenggelam; model hanya memprediksi 175 sampel positif, dengan *recall* 0,0217 dan akurasi 0,4437, di bawah garis dasar mayoritas.

7.4 Akurasi yang Sama Tidak Berarti Proses Belajar yang Sama

Perceptron η = 0,01 (akurasi uji 0,7460) dan ADALINE η = 0,001 (0,7403) berakurasi mirip, tetapi Perceptron mencapainya melalui lebih dari 530.000 pembaruan diskret yang berosilasi, sedangkan ADALINE menempuh 50 langkah gradien mulus yang belum konvergen. *Precision* ADALINE lebih tinggi (0,7958 vs 0,7874) tetapi *recall*-nya lebih rendah (0,7250 vs 0,7521), artinya jenis kesalahannya berbeda. Pada seleksi dengan data validasi independen, Perceptron yang dilatih pada 80% data latih turun ke akurasi validasi 0,6759, sedangkan ADALINE tetap stabil di 0,7996, sehingga bobot Perceptron sensitif terhadap urutan dan subset data.

7.5 Keterbatasan dan Langkah Pengembangan

Keterbatasan:

1. Neuron tunggal hanya membentuk satu hyperplane; model linear optimum pun berhenti di akurasi uji 0,7947 dan tidak dapat menangkap interaksi antarfitur (misalnya cuaca buruk × jarak jauh × metode pengiriman).
2. Bobot akhir Perceptron tidak stabil dan bergantung pada epoch penghentian (0,7460 pada epoch 50 vs 0,7600 pada epoch 18).
3. Data Kaggle menyerupai data sintetis (tanpa nilai hilang dan duplikat) sehingga generalisasi ke data operasional belum teruji; kelas juga sedikit tidak seimbang.
4. Evaluasi memakai satu pembagian 80:20 dengan *seed* 42; variasi antarpembagian belum diukur (misalnya dengan *k-fold cross-validation*).

Langkah pengembangan: (1) *pocket* atau *averaged perceptron* (Gallant, 1990) yang pada percobaan ini menambah sekitar 1,4 poin akurasi uji; (2) ADALINE *mini-batch*/*stochastic* dengan η adaptif; (3) regresi logistik (aktivasi sigmoid dan *cross-entropy*) agar keluaran berupa probabilitas keterlambatan; (4) *Multi-Layer Perceptron* untuk batas keputusan non-linear; (5) rekayasa fitur interaksi dan validasi silang.

8. KESIMPULAN

Berdasarkan implementasi mandiri, verifikasi manual, dan delapan eksperimen pelatihan:

1. Neuron tunggal berhasil mempelajari pola keterlambatan pengiriman. **ADALINE terstandardisasi dengan $\eta = 0{,}1$**, yang dipilih melalui data validasi, menjadi model terbaik dengan akurasi uji **0,7943**, *precision* 0,8240, *recall* 0,8072, dan *F1-score* 0,8155, jauh di atas garis dasar mayoritas 0,5632.
2. Data menunjukkan indikasi kuat tidak terpisah linear: Perceptron tidak konvergen (≈ 10.670 pembaruan per epoch), $J_{\text{LS}} = 0{,}2881$, dan sebaran margin tumpang-tindih. Akurasi sekitar 79% merupakan batas kelas model linear, bukan kegagalan optimisasi.
3. Galat kontinu ADALINE memandu bobot mendekati optimum *least squares* (kosinus 0,9913), sedangkan galat diskret Perceptron menghasilkan bobot yang berosilasi dan sensitif terhadap urutan data.
4. Pada Perceptron berinisialisasi nol, η hanya menskalakan bobot sehingga ketiga konfigurasi identik (terbukti analitis dan numerik); pada ADALINE, η menentukan kecepatan konvergensi dalam 50 epoch.
5. Standardisasi fitur wajib: tanpanya ADALINE divergen pada epoch 31 dan Perceptron jatuh di bawah garis dasar. Peningkatan lebih lanjut memerlukan model non-linear atau rekayasa fitur, bukan sekadar menambah epoch atau mengubah η.

DAFTAR PUSTAKA

E-commerce Delivery and Shipping Data 2026. Kaggle (CC0 1.0). https://www.kaggle.com/datasets/datascikhan/e-commerce-delivery-and-shipping-data-2026

Gallant, S. I. (1990). Perceptron-based learning algorithms. *IEEE Transactions on Neural Networks*, 1(2), 179–191. https://doi.org/10.1109/72.80230

LeCun, Y., Bottou, L., Orr, G. B., & Müller, K.-R. (1998). Efficient BackProp. Dalam *Neural Networks: Tricks of the Trade* (LNCS 1524, hlm. 9–50). Springer. https://doi.org/10.1007/3-540-49430-8_2

Pedregosa, F., dkk. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

Pratama, N., Anrahvi, R., Tambal, A., & Singh, A. (2025). Classification of e-commerce shipping timeliness using supervised learning algorithm. *Public Research Journal of Engineering, Data Technology and Computer Science (PREDATECS)*, 3(1). https://doi.org/10.57152/predatecs.v3i1.1855

Raschka, S. (t.t.). *Adaline: Adaptive Linear Neuron Classifier*. Dokumentasi mlxtend. https://rasbt.github.io/mlxtend/user_guide/classifier/Adaline/ (diakses 6 Oktober 2026)

Raschka, S., & Mirjalili, V. (2019). *Python Machine Learning* (Edisi ke-3). Packt Publishing. https://github.com/rasbt/python-machine-learning-book-3rd-edition

Rosenblatt, F. (1958). The perceptron: A probabilistic model for information storage and organization in the brain. *Psychological Review*, 65(6), 386–408. https://doi.org/10.1037/h0042519

Widrow, B., & Hoff, M. E. (1960). Adaptive switching circuits. *IRE WESCON Convention Record*, Part 4, 96–104. https://isl.stanford.edu/~widrow/papers/c1960adaptiveswitching.pdf

LAMPIRAN A. PERHITUNGAN MANUAL PERCEPTRON DAN ADALINE

Perhitungan memakai empat sampel data latih terstandardisasi dengan tiga fitur: x_1 (*distance_km*), x_2 (*promised_delivery_days*), dan x_3 (*warehouse_processing_hours*), dengan $\eta = 0{,}1$, $\boldsymbol{w}_0 = [0; 0; 0]^{\mathrm{T}}$, dan $b_0 = 0$.

Tabel A1. Sampel mini untuk perhitungan manual

Sampel	Urutan latih	x_1	x_2	x_3	Target y
S_1	5	−0,1654	+1,0307	−0,7766	−1
S_2	0	−0,4735	−1,1432	−0,8371	+1
S_3	6	−0,0029	−0,3280	−0,3228	−1
S_4	1	+0,9708	−0,0562	+0,8472	+1

A.1 Perceptron (dua langkah pembaruan per sampel)

Langkah 1 (S_1, $y = -1$).

$z = 0(-0{,}1654) + 0(1{,}0307) + 0(-0{,}7766) + 0 = 0{,}0000 \geq 0 \Rightarrow \hat{y} = +1$ (salah klasifikasi)

$\Delta = 0{,}1 \times (-1 - (+1)) = -0{,}2000$

$\boldsymbol{w}^{(1)} = [0; 0; 0]^{\mathrm{T}} + (-0{,}2000)[-0{,}1654; 1{,}0307; -0{,}7766]^{\mathrm{T}} = [+0{,}0331; -0{,}2061; +0{,}1553]^{\mathrm{T}}$; $b^{(1)} = -0{,}2000$

Langkah 2 (S_2, $y = +1$).

$z = (0{,}0331)(-0{,}4735) + (-0{,}2061)(-1{,}1432) + (0{,}1553)(-0{,}8371) - 0{,}2000 = -0{,}1100 < 0 \Rightarrow \hat{y} = -1$ (salah klasifikasi)

$\Delta = 0{,}1 \times (+1 - (-1)) = +0{,}2000$

$\boldsymbol{w}^{(2)} = \boldsymbol{w}^{(1)} + 0{,}2000[-0{,}4735; -1{,}1432; -0{,}8371]^{\mathrm{T}} = [-0{,}0616; -0{,}4348; -0{,}0121]^{\mathrm{T}}$; $b^{(2)} = 0{,}0000$

Pengecekan kode: Perceptron(eta=0.1, n_epochs=1).fit(X[:2], y[:2]) menghasilkan $\boldsymbol{w} = [-0{,}0616; -0{,}4348; -0{,}0121]^{\mathrm{T}}$ dan $b = 0{,}0000$, identik dengan perhitungan manual (diverifikasi dengan *assert*).

A.2 ADALINE (dua iterasi batch, n = 4)

Epoch 0. $\boldsymbol{w}^{(0)} = [0; 0; 0]^{\mathrm{T}}$, $b^{(0)} = 0$, sehingga $z_i = 0$ dan $e_i = y_i$. Biaya awal $J^{(0)} = (1/8)[(-1)^2 + 1^2 + (-1)^2 + 1^2] = 0{,}5000$.

Iterasi 1.

$\boldsymbol{e} = [-1{,}0; +1{,}0; -1{,}0; +1{,}0]^{\mathrm{T}}$; $\boldsymbol{X}^{\mathrm{T}}\boldsymbol{e}/4 = [+0{,}1664; -0{,}4755; +0{,}2774]^{\mathrm{T}}$; $\mathrm{mean}(\boldsymbol{e}) = 0{,}0000$

$\boldsymbol{w}^{(1)} = [+0{,}0166; -0{,}0476; +0{,}0277]^{\mathrm{T}}$; $b^{(1)} = 0{,}0000$; $J^{(1)} = 0{,}4679$ (MSE = 0,9358)

Iterasi 2.

$\boldsymbol{z} = [-0{,}0733; +0{,}0233; +0{,}0066; +0{,}0423]^{\mathrm{T}}$; $\boldsymbol{e} = [-0{,}9267; +0{,}9767; -1{,}0066; +0{,}9577]^{\mathrm{T}}$

$\boldsymbol{X}^{\mathrm{T}}\boldsymbol{e}/4 = [+0{,}1558; -0{,}4489; +0{,}2596]^{\mathrm{T}}$; $\mathrm{mean}(\boldsymbol{e}) = +0{,}0003$

$\boldsymbol{w}^{(2)} = [+0{,}0322; -0{,}0924; +0{,}0537]^{\mathrm{T}}$; $b^{(2)} = 0{,}0000$; $J^{(2)} = 0{,}4394$ (MSE = 0,8789)

Pengecekan kode: AdalineGD(eta=0.1, n_epochs=2).fit(X, y) menghasilkan bobot, bias, dan riwayat biaya *cost_* = [0,5000; 0,4679; 0,4394] yang identik dengan kalkulasi analitis (diverifikasi dengan *assert*).

LAMPIRAN B. RIWAYAT PELATIHAN PADA EPOCH KE-10, KE-30, DAN KE-50

Tabel B1. Perceptron: jumlah pembaruan dan akurasi data latih

Konfigurasi	Pembaruan ep. 10	Pembaruan ep. 30	Pembaruan ep. 50	Akurasi ep. 10	Akurasi ep. 30	Akurasi ep. 50
η = 0,001 (std.)	10.642	10.673	10.674	0,7531	0,7501	0,7443
η = 0,01 (std.)	10.642	10.673	10.674	0,7531	0,7501	0,7443
η = 0,1 (std.)	10.642	10.673	10.674	0,7531	0,7501	0,7443
η = 0,01 (tanpa std.)	18.295	17.774	17.447	0,4356	0,4374	0,4430

Tabel B2. ADALINE: biaya *J* dan akurasi data latih

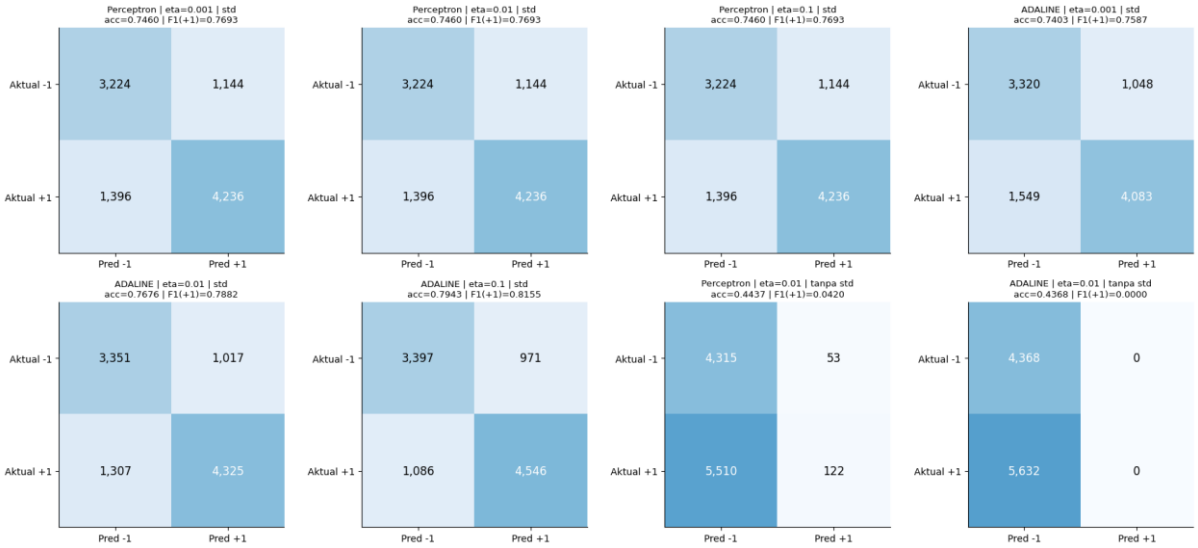
Konfigurasi	*J* ep. 10	*J* ep. 30	*J* ep. 50	Akurasi ep. 10	Akurasi ep. 30	Akurasi ep. 50
η = 0,001 (std.)	0,4940	0,4828	0,4724	0,7400	0,7415	0,7428
η = 0,01 (std.)	0,4493	0,3897	0,3578	0,7460	0,7588	0,7683
η = 0,1 (std.)	0,3210	0,2945	0,2898	0,7807	0,7938	0,7959
η = 0,01 (tanpa std.)	$1{,}28\times10^{98}$	$1{,}43\times10^{297}$	Divergen	0,4368	0,4368	Divergen

LAMPIRAN C. MATRIKS KEBINGUNGAN DATA UJI

Baris adalah label sebenarnya dan kolom adalah prediksi, dengan urutan Tepat Waktu (−1) lalu Terlambat (+1).

Tabel C1. Matriks kebingungan data uji (n = 10.000)

Konfigurasi	TN	FP	FN	TP
Perceptron $\eta \in \{0{,}001; 0{,}01; 0{,}1\}$ (std.)	3.224	1.144	1.396	4.236
ADALINE η = 0,001 (std.)	3.320	1.048	1.549	4.083
ADALINE η = 0,01 (std.)	3.351	1.017	1.307	4.325
ADALINE η = 0,1 (std.)	**3.397**	**971**	**1.086**	**4.546**
Perceptron η = 0,01 (tanpa std.)	4.315	53	5.510	122
ADALINE η = 0,01 (tanpa std.)	4.368	0	5.632	0



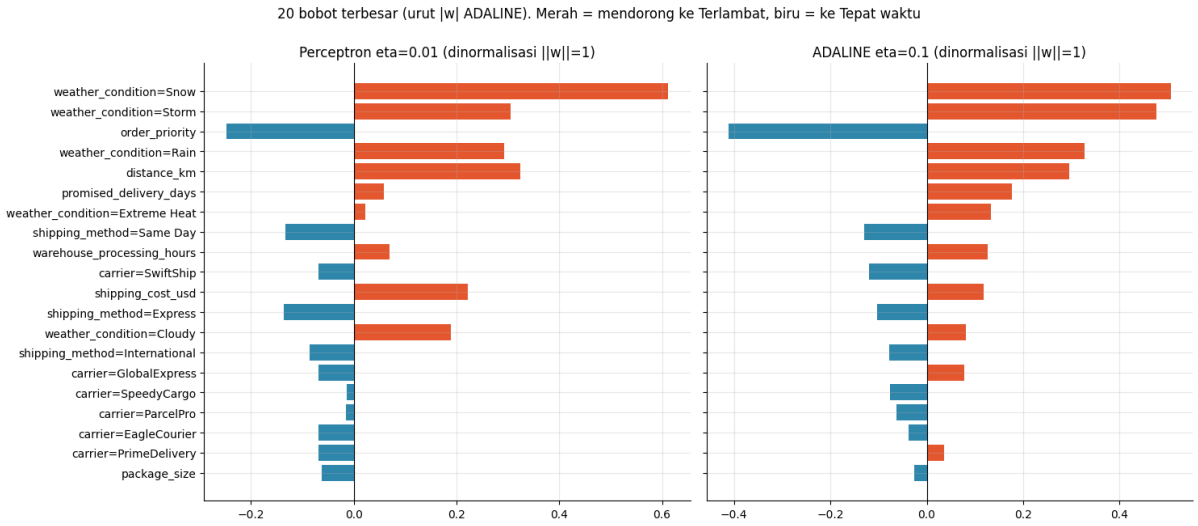
Gambar C1. Matriks kebingungan data uji untuk delapan konfigurasi

LAMPIRAN D. BOBOT DAN BIAS AKHIR

Tabel D1 memuat bobot terbesar menurut $|w|$ ADALINE $\eta = 0{,}1$ pada kedua model terstandardisasi; daftar lengkap 43 bobot untuk delapan konfigurasi tersimpan pada berkas *results/bobot_bias_akhir.csv* di repositori.

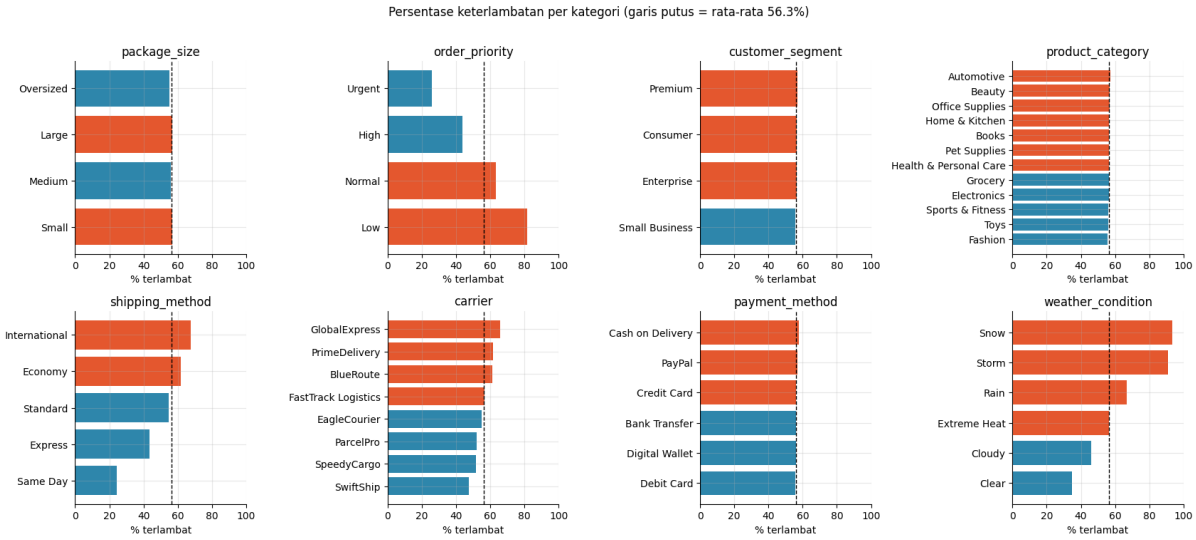
Tabel D1. Bobot terbesar Perceptron ($\eta = 0{,}01$) dan ADALINE ($\eta = 0{,}1$)

Fitur	Perceptron	ADALINE
weather_condition=Snow	+0,6690	+0,3179
weather_condition=Storm	+0,3344	+0,2990
order_priority	−0,2708	−0,2584
weather_condition=Rain	+0,3202	+0,2062
distance_km	+0,3539	+0,1860
bias (b)	+0,2000	+0,1258
promised_delivery_days	+0,0648	+0,1106
weather_condition=Extreme Heat	+0,0240	+0,0841
shipping_method=Same Day	−0,1452	−0,0816
warehouse_processing_hours	+0,0767	+0,0792
carrier=SwiftShip	−0,0755	−0,0749
shipping_cost_usd	+0,2428	+0,0738
shipping_method=Express	−0,1488	−0,0648
weather_condition=Cloudy	+0,2065	+0,0513

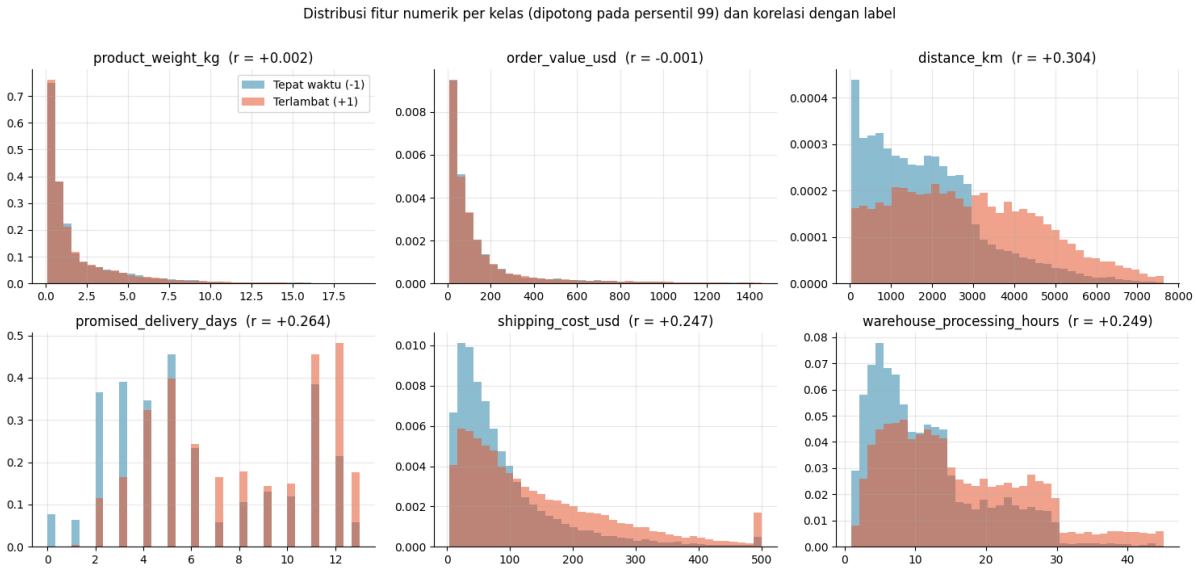


Gambar D1. Dua puluh bobot terbesar (merah mendorong ke Terlambat, biru ke Tepat Waktu)

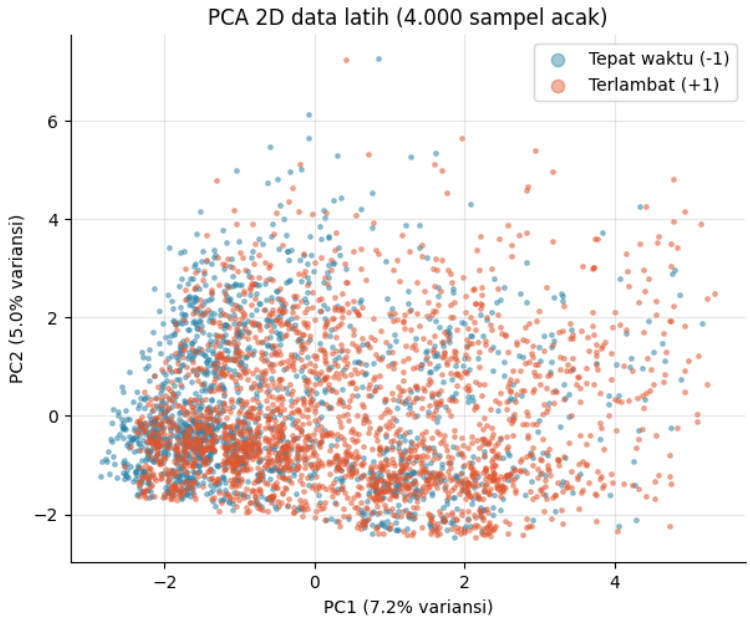
LAMPIRAN E. GAMBAR PENDUKUNG



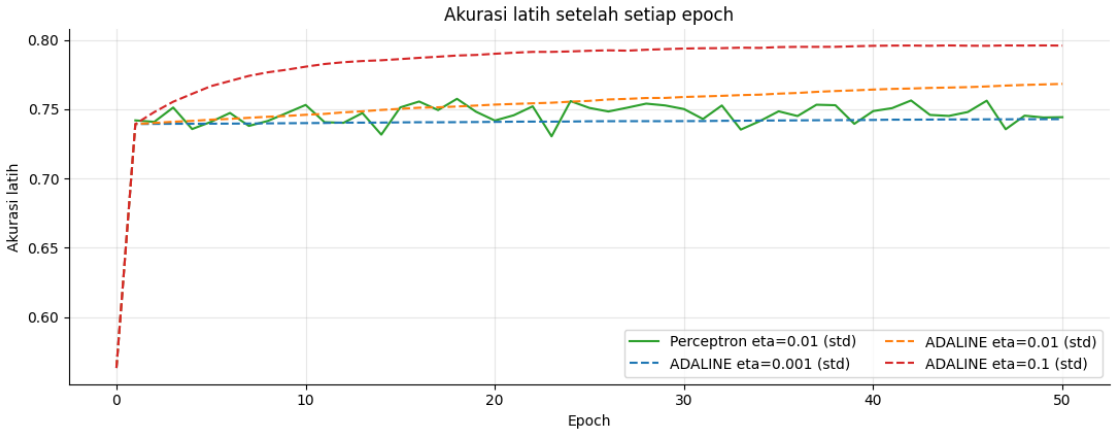
Gambar E1. Persentase keterlambatan per kategori (garis putus-putus adalah rata-rata keseluruhan)



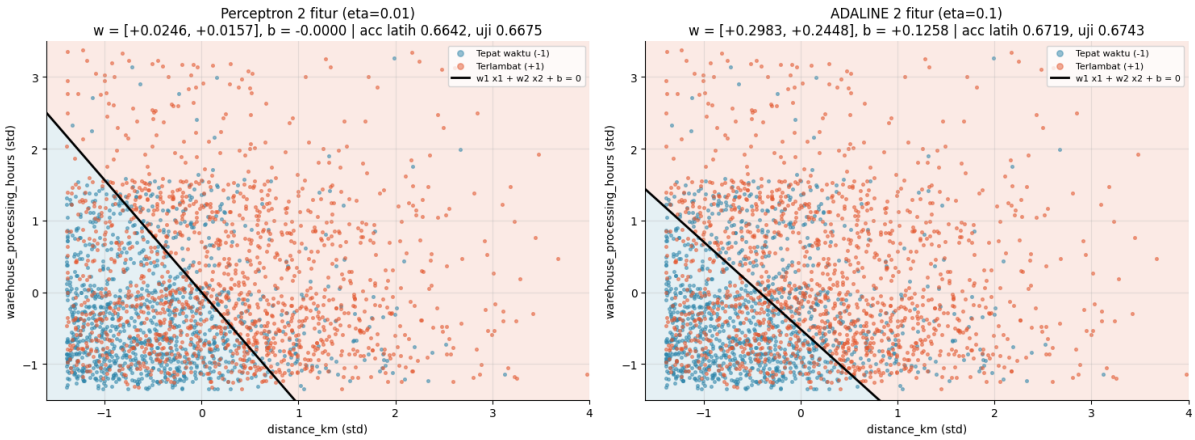
Gambar E2. Distribusi fitur numerik per kelas (dipotong pada persentil 99) dan korelasi dengan label



Gambar E3. PCA 2D data latih terstandardisasi (4.000 sampel acak)



Gambar E4. Akurasi latih setelah setiap epoch: Perceptron berosilasi, ADALINE naik mulus



Gambar E5. Batas keputusan model bantu dua fitur (*distance_km* dan *warehouse_processing_hours*)

LAMPIRAN F. PERNYATAAN BANTUAN AI

Asisten AI generatif dipakai untuk membantu menyusun kerangka kode, visualisasi, serta draf narasi notebook dan README. Cara kelompok memverifikasi hasilnya:

1. Perhitungan manual 2 langkah Perceptron dan 2 iterasi ADALINE dicek dengan *assert* agar identik dengan keluaran kelas yang dipakai dalam eksperimen.
2. Standardisasi buatan sendiri dicek identik dengan *sklearn.preprocessing.StandardScaler* yang di-*fit* pada data latih, dan tidak ada irisan indeks latih–uji (*assert*).
3. Invariansi η Perceptron dicek numerik (w/η identik dan prediksi identik).
4. ADALINE dicek silang dengan solusi *least squares* tertutup, dan Perceptron dengan *sklearn.linear_model.Perceptron* (akurasi uji 0,7569 dengan kosinus arah bobot 0,9423 terhadap Perceptron mandiri).
5. Notebook dieksekusi ulang dari awal dengan hasil yang sama, dan setiap angka pada pembahasan dicocokkan dengan keluaran sel.

Setiap anggota bertanggung jawab memahami dan mampu menjelaskan seluruh isi repositori.

LAMPIRAN G. KONTRIBUSI ANGGOTA

Beban kerja dibagi merata (masing-masing sekitar 20%). Setiap anggota memegang satu bagian inti kode, satu bagian analisis, dan satu bagian luaran (laporan, presentasi, atau repositori).

Tabel G1. Pembagian kontribusi anggota kelompok

Anggota (NIM)	Kode / eksperimen	Analisis & pembahasan	Laporan & repositori
Stefanus Westin Giovanno Mursito (71241073)	*prepare_dataset.py*, pemilihan fitur dan pembuangan kolom bocor, kelas *Preprocessor*, *split* stratified	Kualitas data, EDA, PCA 2D	Laporan bagian 1–2; slide kasus dan data
Giovanni Albert Harjanto (71241075)	Kelas *Perceptron*, perhitungan manual Perceptron dan *assert*	Invariansi η, inisialisasi acak, *pocket*, pembanding scikit-learn	Laporan bagian 4 (Perceptron) dan lampiran manual; slide Perceptron
Natalie Neysa Jessica Soesanto (71241079)	Kelas *AdalineGD*, perhitungan manual ADALINE dan *assert*	*Least squares*, syarat stabilitas η, analisis divergensi tanpa standardisasi	Laporan bagian 4 (ADALINE) dan 5; slide ADALINE
Fransiska (71241123)	Rancangan dan eksekusi 8 pelatihan, tabel epoch 10/30/50, kurva, matriks kebingungan	Metrik kelas positif, histogram jarak hyperplane, *decision boundary* 2 fitur	Laporan bagian 6; slide hasil dan demo notebook
Kevin Surya Saputra (71241150)	Seleksi model dengan data validasi, bobot dan bias akhir, ekspor *figures/* dan *results/*	Penelusuran artikel dan kode rujukan, interpretasi bobot, keterbatasan	Laporan bagian 3 dan 7–9; README dan pengelolaan repositori